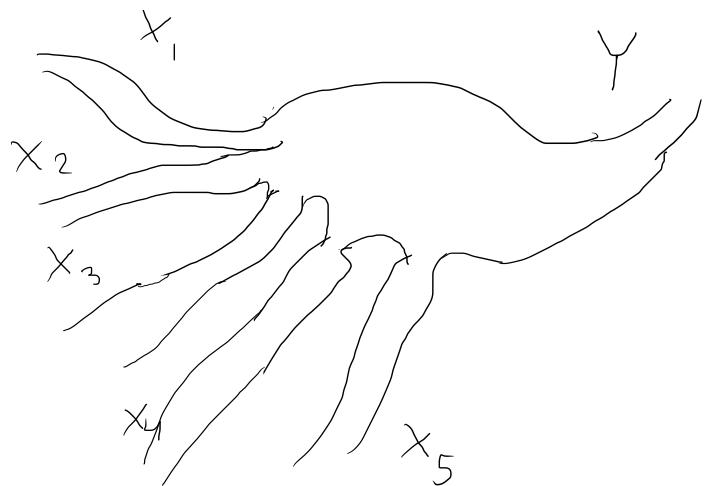


Antecedentes: 1943 McCulloch-Pitts

Se considera la neurona



$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_5 \end{pmatrix} = \text{Señal de entrada}$$

$$y = \text{Señal de salida}$$

La señal X se procesa en la neurona.

El procesamiento se describe como una asignación de Pesos a cada señal en términos de una transformación lineal

$$X \rightarrow \sum w_i X_i \in \mathbb{R}$$

Con $w_i \in \mathbb{R}$, esos se nombran pesos

La señal puede activar o no a la neurona

Este fenómeno se describe de la sig. forma:

Suponemos que existe un umbral de activación que denotamos con $\theta \in \mathbb{R}$

Entonces, si

$$\sum w_i X_i \geq \theta,$$

la neurona se activa

Si $\sum w_i x_i < \theta$, la neurona no se activa.

De manera matemática se modela con la función característica o indicador χ :

Dado un conjunto A , definimos

$$\chi_A(x) = \begin{cases} 1 & \text{si } x \in A \\ 0 & \text{si } x \notin A \end{cases} \quad \begin{pmatrix} \chi_A(x), \text{ en} \\ \text{probabilidad} \end{pmatrix}$$

Denotamos por $\mathbb{R}^+ = [0, \infty)$

Entonces el proceso de activación se describe de la sig manera:

$$\chi_{\mathbb{R}^+}(\sum w_i x_i - \theta),$$

de forma que si x es tal que

$\chi_{\mathbb{R}^+}(\sum w_i x_i - \theta) = 1$, entonces la neurona se activa y si

$\chi_{\mathbb{R}^+}(\sum w_i x_i - \theta) = 0$, entonces la neurona no se activa.

La señal de salida y describe el proceso de activación

$$y(x) = \chi_{\mathbb{R}^+}(\xi w_i x_i - \theta)$$

y la interpretación es

$$y(x) = \begin{cases} 1, & \text{la neurona se activa} \\ 0, & \text{la neurona no se activa} \end{cases}$$

En el caso anterior se tienen los sig. objetos matemáticos

$x \in \mathbb{R}^5$ señal de entrada

$$T: \mathbb{R}^5 \rightarrow \mathbb{R}, T(x) = \xi w_e x_e - \theta, \begin{matrix} \text{procesamiento} \\ \text{de la señal} \\ \text{y umbral} \end{matrix}$$

$\chi_{\mathbb{R}^+}$

$$y(x) = \chi_{\mathbb{R}^+}(T(x))$$

función de activación

señal de salida

De forma general, se considera el siguiente modelo:

1. $T: \mathbb{R}^m \rightarrow \mathbb{R}^n$ una transformación afín.

Recordar que una transformación afín es una transformación lineal compuesta con una traslación:

$$T(x) = Ax + \theta$$

con A una transformación lineal y $\theta \in \mathbb{R}^n$. A se puede representar como una matriz. Normalmente se identifica a A con la matriz que la representa en las bases canónicas de \mathbb{R}^m y \mathbb{R}^n y las componentes de A , A_{e_j} , se nombran pesos.

2. $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ es una función de activación.
(φ es cualquier función)

Usando φ , se pueden definir funciones que denotamos temporalmente por

$$\varphi^n: \mathbb{R}^n \rightarrow \mathbb{R}^n,$$

definida por

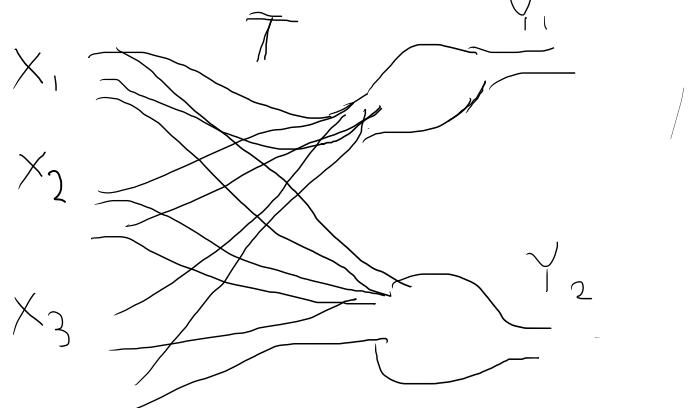
$$\varphi^n \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix} := \begin{pmatrix} \varphi(z_1) \\ \varphi(z_2) \\ \vdots \\ \varphi(z_n) \end{pmatrix}, \text{ con } z_i \in \mathbb{R}, \forall i.$$

φ^n y φ son funciones distintas, sin embargo normalmente se identifican y se omite el superíndice n. Es decir

$$\varphi^n \equiv \varphi$$

de manera que se genera un
abuso de notación que se usa todo el tiempo
en el contexto de redes neuronales.

En este contexto tenemos la sig. figura



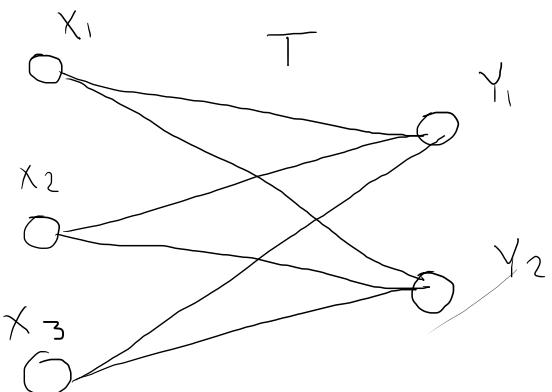
$$T: \mathbb{R}^3 \rightarrow \mathbb{R}^2$$

transformación
afin

$$X = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \text{señal de entrada}$$

$$f \circ T(x) = f(T(x)) = Y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \text{señal de salida}$$

De forma esquemática se usa la siguiente figura



Las bolitas nombran neuronas. Las líneas representan señales. $\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$ es la capa de entrada. $\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$ es la capa de salida.

De forma general, se pueden considerar capas intermedias (capas ocultas) entre \mathbf{x} y \mathbf{y}

de manera que la señal de entrada pasa por varias neuronas agrupadas en capas antes de llegar a la señal de salida

Este proceso de señales transmitidas y análisis se Perceptrón multi-capa y es el objeto fundamental de las redes neuronales.

Def. Perceptrón Multi-Capa.

Un perceptrón multi-capa

"Multilayer Perceptron (MLP)" de dimensión d_1 niveles y función de activación f es una función

$$f: \mathbb{R}^d \rightarrow \mathbb{R}^n$$

que tiene las sig. propiedades

Existe un arreglo de transformaciones afines

$$\phi = (T_1, T_2, \dots, T_L)$$

en donde T_i es afín, para toda i ,
tales que

$$f = R_g(\phi) \equiv R(\phi),$$

en donde

$$R(\phi) = T_L \circ \rho \circ T_{L-1} \circ \rho \circ T_{L-2} \circ \rho \dots \circ \rho \circ T_1$$

Los dominios y rangos de las transformaciones afines tienen que ser compatibles para que f tenga sentido.

Ademas se tiene que cumplir
 $\text{dom}(T_1) = \mathbb{R}^d$.

Def. (Red Neuronal).

Al arreglo de transformaciones afines que se describe en la def. anterior se le nombra red neuronal

$$\phi = (T_1, T_2, \dots, T_L) \quad \text{red neuronal}$$

Def. (Realización de una Red Neuronal)

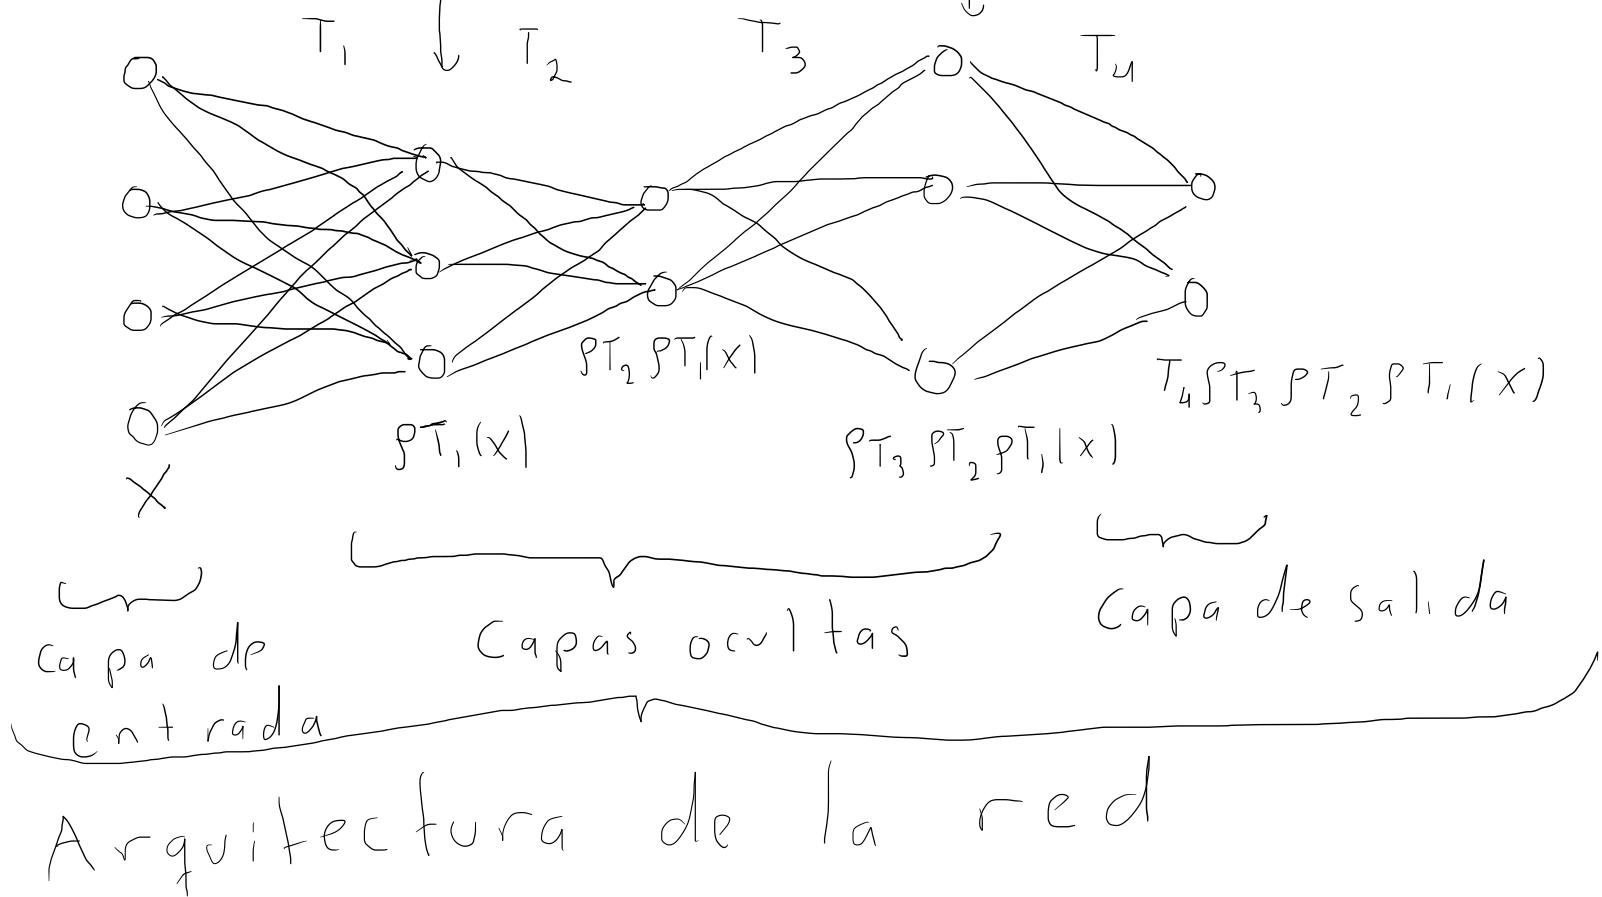
La función

$$R: \text{Redes Neuronales} \rightarrow \text{Perceptrones Multicapa}$$

$$R(\phi) = T_L \circ \rho \circ T_{L-1} \circ \rho \dots \circ \rho \circ T_1$$

Es nombrada realización de la red neuronal $\phi = (T_1, T_2, \dots, T_L)$.

Representación gráfica de una red
neuronal



Podemos considerar la sucesión de señales

$$x_0 = x \quad = \text{señal de entrada}$$

$$x_1 = f_{T_1}(x)$$

$$x_2 = f_{T_2} f_{T_1}(x) = f_{T_2}(x_1)$$

$$x_3 = f_{T_3}(x_2)$$

$$x_u = f_{T_u}(x_3) \quad \text{señal de salida}$$

Entonces x_e se puede ver como la señal de entrada de la red

$$\text{neuronal } (T_{p+1}, \dots, T_u).$$

$y = x_u$ es la señal de salida.

Operaciones con Redes Neuronales

Dada una transformación afín,
existe una matriz A y un vector b
tales que

$$T(x) = Ax + b \quad (A \text{ y } b \text{ expresadas en bases canónicas})$$

Identificamos

$$T = (A, b)$$

Dado $x \in \mathbb{R}^d$ usamos como antes la notación

$$x_0 = x, \quad x_1 = \phi(T_1, x_0), \quad \dots, \quad x_\ell = \phi(T_\ell, x_{\ell-1}), \quad \dots, \quad x_L = T_L x_{L-1}$$

En donde $\phi = (T_1, T_2, \dots, T_L)$

Entonces $R(\phi)$ manda a x en x_L

Supongamos que $T_e : \mathbb{R}^{N_{e-1}} \rightarrow \mathbb{R}^{N_e}$, $N_d = d$
Definimos

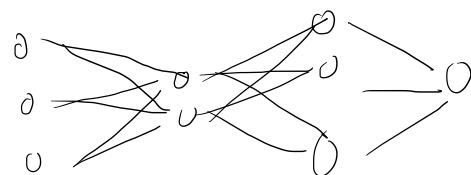
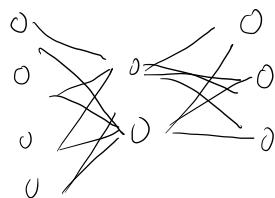
1. Dimensión de entrada = d
2. Número de niveles o capas = $L \equiv L(\phi)$
3. Número de neuronas := $d + \sum_j^L N_j$
4. Dada una matriz A y un vector b
denotamos por
 $\|A\|_0$ = entradas no cero de A .
 $\|b\|_0$ = entradas no cero de b
Dada una transformación afín
 $T = (A, b)$, denotamos
 $\|T\|_0 = \|A\|_0 + \|b\|_0$
5. Denotamos por
 $m_j(\phi) = \|T_j\|_0$,

7.- Denotamos por $M(\psi) = \sum_{j=1}^L M_j(\psi)$

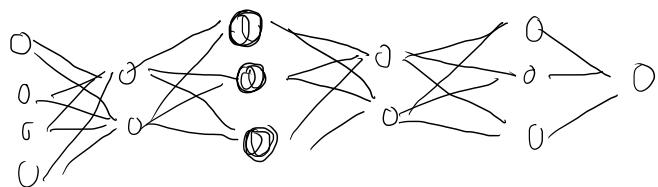
8.- Dimensión de salida := N_L

Def (concatenación)

Explicación intuitiva. Supongamos que tenemos las sig. redes



Concatenar significa "pegar" las rede de forma horizontal, formando la sig. red



Sean $\phi^{(1)}, \phi^{(2)}, \dots, \phi^{(n)}$ redes neuronales
 con $\phi^{(j)} = (T_1^{(j)}, \dots, T_{\theta_j}^{(j)})$

Definimos

$$\begin{aligned} \phi^{(1)} \cdot \phi^{(2)} \cdot \dots \cdot \phi^{(n)} &:= \\ (T_1^{(n)}, T_2^{(n)}, \dots, T_{\theta_{n-1}}^{(n)}, T_1^{(n-1)} \circ T_{\theta_n}^{(n)}, T_2^{(n-1)}, T_3^{(n-1)}, \dots, \\ T_{\theta_{n-1}-1}^{(n-1)}, T_1^{(n-2)} \circ T_{\theta_{n-1}}^{(n-1)}, T_2^{(n-2)}, \dots) \\ T_1^{(2)} \circ T_{\theta_3}^{(2)}, T_2^{(2)}, \dots, T_{\theta_2-1}^{(2)}, T_1^{(1)} \circ T_{\theta_2}^{(2)}, T_2^{(1)}, \dots, T_{\theta_1}^{(1)} \end{aligned}$$

Esta es una red neuronal de

$$\sum_{j=1}^k \theta_j - (k-1)$$

Esto se puede hacer siempre y cuando la dimensión de salida de

$\phi^{(j)}$ coincida con la dimensión de entradas de $\phi^{(j-1)}$, para toda j .

Prop.

$$R(\phi^{(1)} \circ \phi^{(2)} \circ \dots \circ \phi^{(n)}) = R(\phi^{(1)}) \circ R(\phi^{(2)}) \circ \dots \circ R(\phi^{(n)})$$

Dem

$$\begin{aligned} & R(\phi^{(1)} \circ \phi^{(2)} \circ \dots \circ \phi^{(n)}) = \\ & T_{\theta_1}^{(1)} \circ \cancel{\rho} \circ \dots \cancel{\rho} \circ \overline{T}_2^{(1)} \circ \cancel{\rho} \circ \overline{T}_1^{(1)} \circ \cancel{\rho} \circ \overline{T}_{\theta_2}^{(2)} \circ \cancel{\rho} \circ T_{\theta_2-1}^{(2)} \\ & \cancel{\rho} \circ \cancel{\rho} \circ \cancel{\rho} \circ T_2^{(2)} \circ \cancel{\rho} \circ \overline{T}_1^{(2)} \circ \cancel{\rho} \circ T_{\theta_3}^{(3)} \circ \cancel{\rho} \circ \dots \cancel{\rho} \circ T_2^{(k-1)} \circ \cancel{\rho} \circ T_1^{(k-1)} \circ \cancel{\rho} \circ T_{\theta_k}^{(k)} \circ \cancel{\rho} \\ & \circ T_{\theta_{k-1}}^{(n)} \circ \cancel{\rho} \circ \dots \circ T_2^{(n)} \circ \cancel{\rho} \circ T_1^{(n)} = R(\phi^{(1)}) \circ R(\phi^{(2)}) \circ \dots \circ R(\phi^{(n)}) \end{aligned}$$



Def. Dadas $T^{(1)}, T^{(2)}, \dots, T^{(k)}$
transformaciones afines, definimos

1.- (En el caso de que $T^{(1)}, T^{(2)}, \dots, T^{(k)}$
actúen en el mismo espacio)

$$\left(\begin{array}{c} T^{(1)} \\ T^{(2)} \\ \vdots \\ T^{(k)} \end{array} \right) (x) = \left(\begin{array}{c} T^{(1)}(x) \\ T^{(2)}(x) \\ \vdots \\ T^{(k)}(x) \end{array} \right)$$

$$Z = T_1 \oplus T_2 \oplus \dots \oplus T_K \begin{pmatrix} X^{(1)} \\ X^{(2)} \\ X^{(3)} \\ \vdots \\ X^{(K)} \end{pmatrix} = \begin{pmatrix} T_1(X^{(1)}) \\ T_2(X^{(2)}) \\ \vdots \\ T_K(X^{(K)}) \end{pmatrix}$$

Def. Dadas redes neuronales

$$\phi^{(j)} = \left(T_1^{(j)}, T_2^{(j)}, \dots, T_L^{(j)} \right) \quad j \in \{1, 2, \dots, K\}$$

Definimos

$$1. P \left(\phi^{(1)}, \phi^{(2)}, \dots, \phi^{(n)} \right) =$$

$$\left(T_1^{(1)}, T_2^{(1)} \oplus \bar{T}_2^{(n)}, T_3^{(1)} \oplus \bar{T}_3^{(n)}, \dots, T_L^{(1)} \oplus \bar{T}_L^{(n)} \right)$$

$T_1^{(1)}$
 $T_2^{(2)}$
 \vdots
 $T_L^{(n)}$

Si las dimensiones de entrada de $\phi^{(1)}, \phi^{(2)}, \dots, \phi^{(n)}$

Son las mismas

$$2. F_P \left(\phi^{(1)}, \phi^{(2)}, \dots, \phi^{(n)} \right) =$$

$$\left(\bar{T}_1^{(1)} \oplus \bar{T}_1^{(n)}, T_2^{(1)} \oplus \bar{T}_2^{(n)}, \dots, T_L^{(1)} \oplus \bar{T}_L^{(n)} \right)$$

Prop

$$1. M | P(\psi^{(1)}, \psi^{(2)}, \dots, \psi^{(n)}) = \sum_j M(\psi^{(j)}) \\ = M(FP(\psi^{(1)}, \psi^{(2)}, \dots, \psi^{(n)}))$$

$$2. R(P(\psi^{(1)}, \psi^{(2)}, \dots, \psi^{(n)}))(x) = \begin{cases} R(\psi^{(1)})(x) \\ R(\psi^{(2)})(x) \\ \vdots \\ R(\psi^{(n)})(x) \end{cases}$$

Tarea

$$R(FP(\psi^{(1)}, \psi^{(2)}, \dots, \psi^{(n)})) \begin{pmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{pmatrix} = \begin{cases} R(\psi^{(1)})(x^{(1)}) \\ \vdots \\ R(\psi^{(n)})(x^{(n)}) \end{cases}.$$

Dém de 2.

$$R(P(\phi^{(1)}, \phi^{(2)}, \dots, \phi^{(k)})) \quad (\times)$$

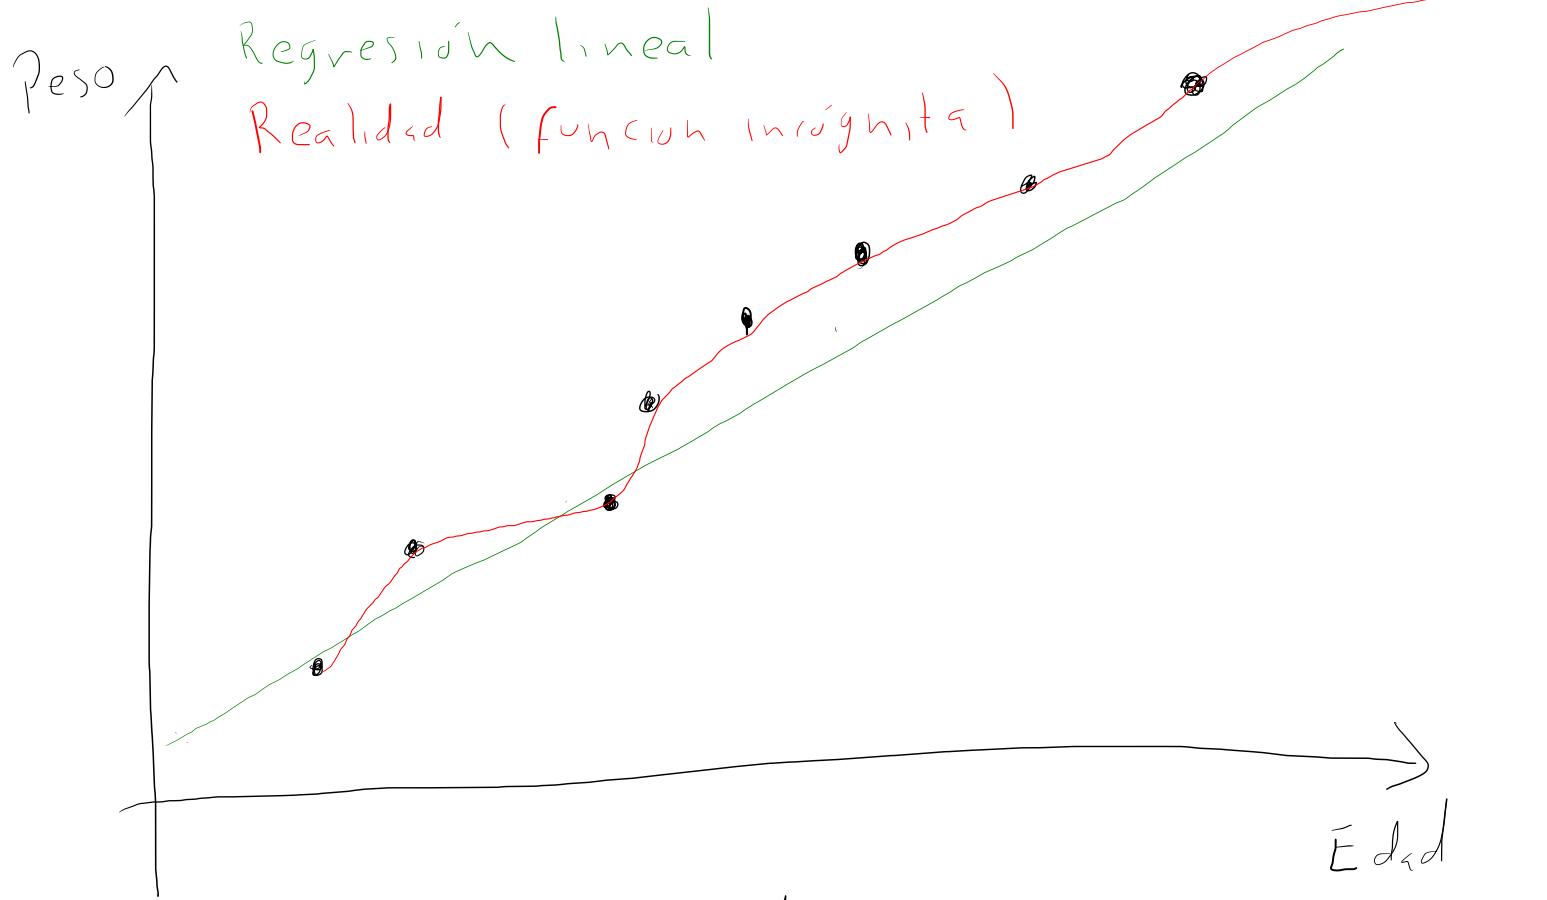
$$= R\left(\left(T_1^{(1)} \begin{array}{c} \\ \vdots \\ T_1^{(k)} \end{array}, T_2^{(1)} \oplus \dots \oplus T_2^{(k)}, \dots, T_L^{(1)} \oplus \dots \oplus T_L^{(k)}\right) \quad (\times)\right)$$

$$= T_L^{(1)} \oplus \dots \oplus T_L^{(k)} \circ P \circ \dots \circ T_2^{(1)} \oplus \dots \oplus T_2^{(k)} \begin{pmatrix} f(T_1^{(1)}(\times)) \\ \vdots \\ f(T_1^{(k)}(\times)) \end{pmatrix}$$

$$= T_L^{(1)} \oplus \dots \oplus T_L^{(k)} \circ P \circ \dots \circ T_3^{(1)} \oplus \dots \oplus T_3^{(k)} \circ P \begin{pmatrix} T_2^{(1)} \begin{pmatrix} P(T_1^{(1)}(\times)) \\ \vdots \\ P(T_1^{(k)}(\times)) \end{pmatrix} \\ T_2^{(k)} \begin{pmatrix} P(T_1^{(1)}(\times)) \\ \vdots \\ P(T_1^{(k)}(\times)) \end{pmatrix} \end{pmatrix}$$

$$\begin{aligned}
&= \left(T_L^{(1)} \circ \rho \circ \bar{T}_{L-1}^{(1)} \circ \rho \circ \dots \circ T_3^{(1)} \circ \rho \circ T_2^{(1)} \circ \rho \circ \bar{T}_1^{(1)}(x) \right. \\
&\quad \left. T_L^{(2)} \circ \rho \circ \bar{T}_{L-1}^{(2)} \circ \rho \circ \dots \circ T_3^{(2)} \circ \rho \circ T_2^{(2)} \circ \rho \circ \bar{T}_1^{(2)}(x) \right. \\
&\quad \left. \vdots \right. \\
&\quad \left. \vdots \right. \\
&\quad \left. T_L^{(k)} \circ \rho \circ \bar{T}_{L-1}^{(k)} \circ \rho \circ \dots \circ T_3^{(k)} \circ \rho \circ T_2^{(k)} \circ \rho \circ \bar{T}_1^{(k)}(x) \right) \\
&= \left(R \psi^{(1)}(x), R \psi^{(2)}(x), \dots, R \psi^{(k)}(x) \right)
\end{aligned}$$





Medimos pesos y edades de personas
Deseo: Que la linea recta aproxime a la
función de la realidad.

Resuesta al despo:

No todas las funciones se
pueden aproximar con líneas
rectas

Alternativa: Considerar otras familias
de funciones que si puedan aproximar
a cualquier función. Por ejemplo

1. Polinomios (aproximan a las funciones
continuas definidas en
intervalos cerrados y
acotados).

2. Series de Fourier.

3. Realizaciones de redes neuronales

Prop Sean f_1, f_2, \dots, f_K

$$f_i : \mathbb{R}^d \rightarrow \mathbb{R}^{m_i}$$

Supongamos que dada $\varepsilon > 0$ existe

una red neuronal $\phi_{\varepsilon}^{(i)}$ tal que
 $\| R\phi_{\varepsilon}^{(i)}(x) - f_i(x) \| \leq \varepsilon, \quad \forall x \in \mathbb{R}^d.$

Entonces, para toda $\varepsilon > 0$ existe una
red neuronal ϕ_{ε} tal que

$$\left\| R\phi_{\varepsilon}(x) - \begin{pmatrix} f_1(x) \\ \vdots \\ f_K(x) \end{pmatrix} \right\| \leq \varepsilon, \quad \forall x \in \mathbb{R}^d.$$